Amazon India E-commerce Sales Analysis & Demand Forecasting

Киселев Артём — Junior Data Analyst
Date: 10/2025
GitHub: Tema Kiselev (temakiselevv) | Telegram: @tema_kiselev

Цели и задачи проекта

- Провести глубокий разведочный анализ продаж;
- Выявить ключевые драйверы выручки и паттерны поведения клиентов ;
- Сегментировать клиентов с помощью RFM-анализа ;
- Построить модель предсказания количества продаж (qty);
- Сформулировать бизнес-рекомендации.

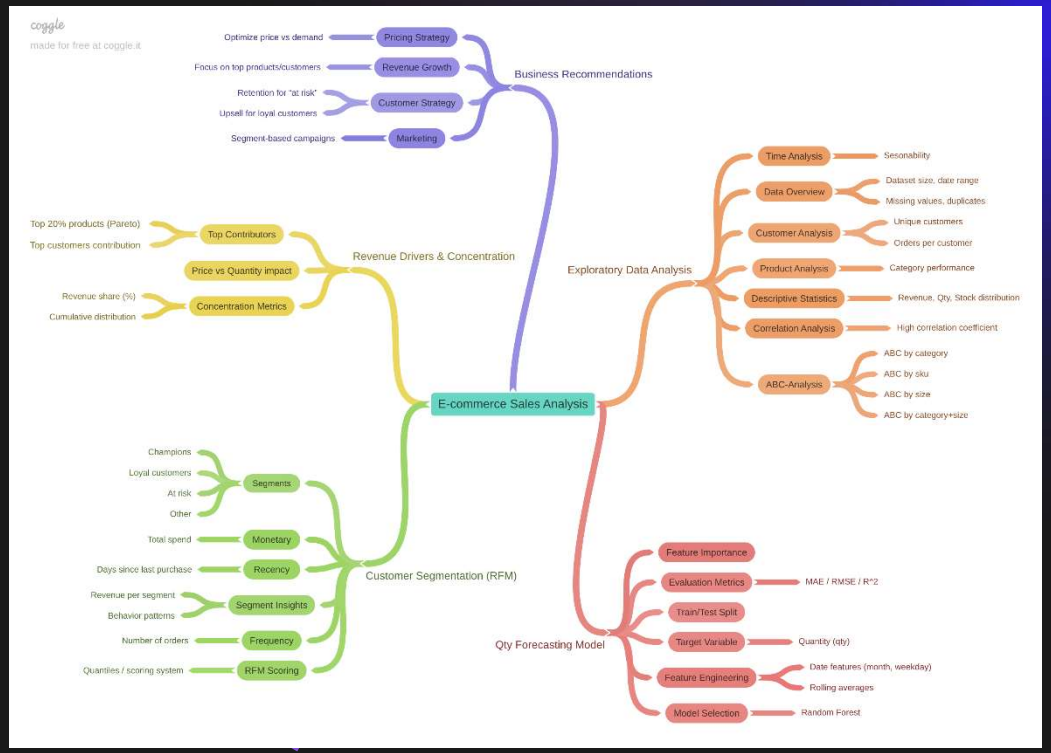

Описание датасета

Amazon Sale Report (Unlock Profits dataset)

- Ключевые поля: date, category, size, qty, revenue, stock, fulfilment, ship-state и др.;
- Период: март – июнь 2022;
- ~129k строк.

	index	Order ID	Date	Status	Fulfilment	Sales Channel	ship-service-level	Style	SKU	Category	...	currency	Amount	ship-city	ship-state	ship-postal-code
0	0	405-8078784-5731545	04-30-22	Cancelled	Merchant	Amazon.in	Standard	SET389	SET389-KR-NP-S	Set	...	INR	647.62	MUMBAI	MAHARASHTRA	400081.0
1	1	171-9198151-1101146	04-30-22	Shipped - Delivered to Buyer	Merchant	Amazon.in	Standard	JNE3781	JNE3781-KR-XXXL	kurta	...	INR	406.00	BENGALURU	KARNATAKA	560085.0
2	2	404-0687676-7273146	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3371	JNE3371-KR-XL	kurta	...	INR	329.00	NAVI MUMBAI	MAHARASHTRA	410210.0
3	3	403-9615377-8133951	04-30-22	Cancelled	Merchant	Amazon.in	Standard	J0341	J0341-DR-L	Western Dress	...	INR	753.33	PUDUCHERRY	PUDUCHERRY	605008.0
4	4	407-1069790-7240320	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3671	JNE3671-TU-XXXL	Top	...	INR	574.00	CHENNAI	TAMIL NADU	600073.0

```
Data columns (total 24 columns):
 #   Column              Non-Null Count   Dtype
---  ------              --------------   -----
 0   index               128975 non-null  int64
 1   Order ID            128975 non-null  object
 2   Date                128975 non-null  object
 3   Status              128975 non-null  object
 4   Fulfilment          128975 non-null  object
 5   Sales Channel       128975 non-null  object
 6   ship-service-level  128975 non-null  object
 7   Style               128975 non-null  object
 8   SKU                 128975 non-null  object
 9   Category            128975 non-null  object
 10  Size                128975 non-null  object
 11  ASIN                128975 non-null  object
 12  Courier Status      122103 non-null  object
 13  Qty                 128975 non-null  int64
 14  currency            121180 non-null  object
 15  Amount              121180 non-null  float64
 16  ship-city           128942 non-null  object
 17  ship-state          128942 non-null  object
 18  ship-postal-code    128942 non-null  float64
 19  ship-country        128942 non-null  object
 20  promotion-ids       79822 non-null   object
 21  B2B                 128975 non-null  bool
 22  fulfilled-by        39277 non-null   object
 23  Unnamed: 22         79925 non-null   object
dtypes: bool(1), float64(2), int64(2), object(19)
memory usage: 22.8+ MB
```

Data Cleaning & Feature Engineering

Data Cleaning:

- Удалены поля, не имеющие значения для дальнейшего анализа (index, unnamed:_22, fulfilled_by);
- Удалены строки с NaN-значениями полей, имеющих ключевое значение в анализе (sku, date, stock), а также строки с некорректными данными (qty <= 0, amount < 0, stock < 0);
- Преобразованы типы полей.

Feature Engineering (подготовка данных для обучения модели):

- Для датафрейма «amazon_sales» добавлены поля year, month, is_fulfilled_by_amazon, агрегированы значения qty, revenue, is_fulfilled_by_amazon, category, size по группе «sku, year, month»;
- Для датафрейма «stock» суммированы значения поля stock по sku, stock переименован в stock_sum;
- Оба датафрейма объединены в общий df_ml с помощью merge, посчитаны новые поля in_stock, stock_log, category_avg_qty.

Exploratory Data Analysis — общая картина

- Выручка за 4 месяца: 75.4 млн INR;
- Продано 116 479 единиц;
- Средний чек ~647 INR;
- Сильная концентрация по категориям и стоку.

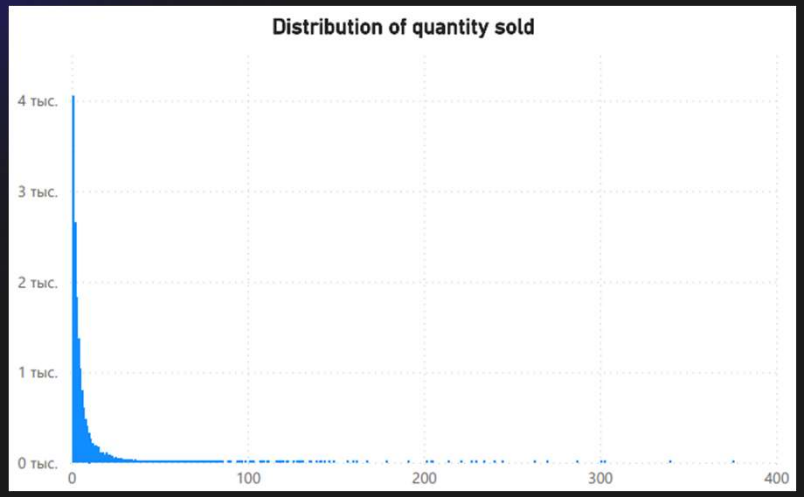

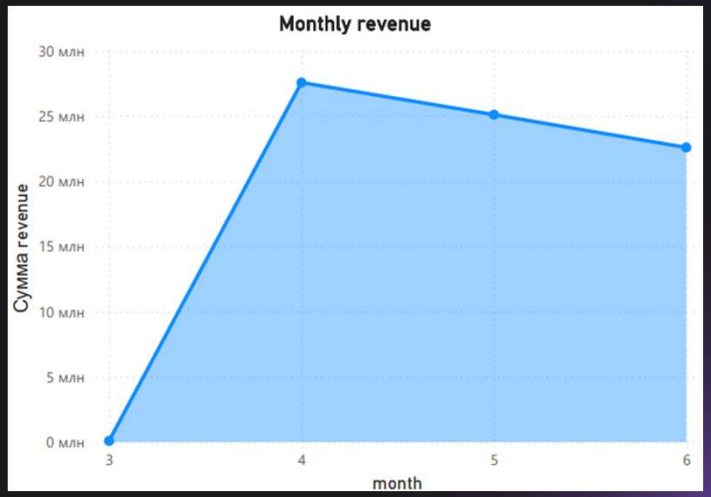

Exploratory Data Analysis — топ-категории и Pareto

- Set → 49.95% выручки
- Set + kurta → 77.07%
- Топ-3 категории → 91.17%
- Классический 80/20

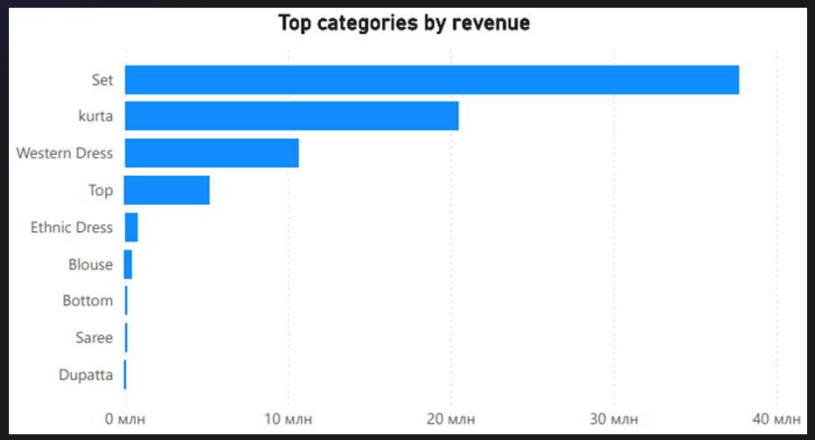

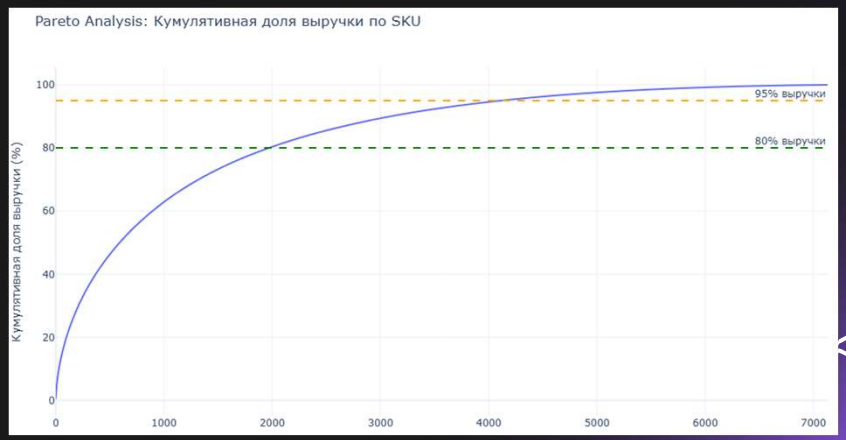

Exploratory Data Analysis — влияние стока и фулфилмента

- Товары в наличии продаются на 26.6% лучше
- Amazon Fulfillment: средний чек 5271 INR (vs 1588 у Merchant)

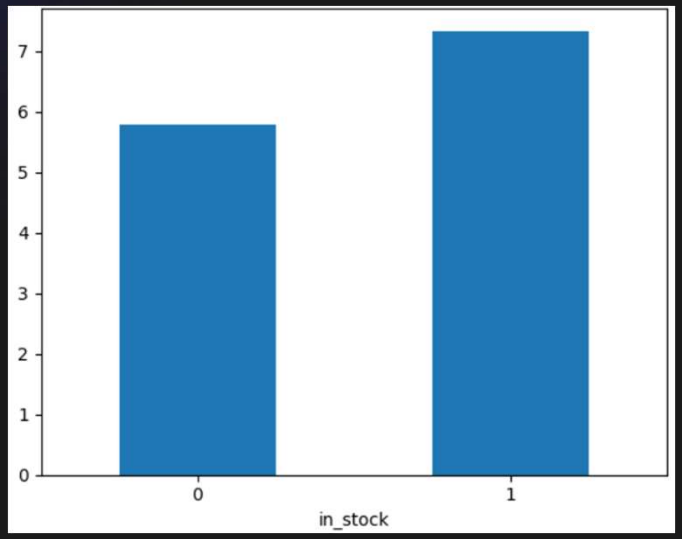

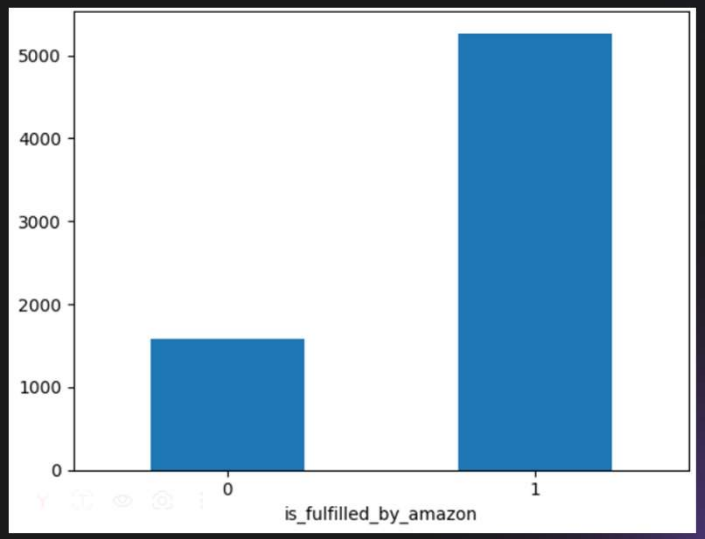

RFM-сегментация клиентов

- Champions + Loyal Customers (42.8% клиентов) → 91.5% выручки
- Lost — 24.34% клиентов → всего 3.2% выручки
- Высокая концентрация дохода в 2 сегментах

Визуализация RFM-результатов

- Основная выручка от небольшой группы лояльных клиентов
- Большой «хвост» неэффективных покупателей
- Слабый переходный слой (Promising почти пустой)

Segment	Customers	Pct_Customers	Total_Revenue	Pct_Revenue	Avg_Recency	Avg_Frequency	Avg_Order_Value
Champions	3240	23.44	62835235.0	83.34	7.39	18.08	658.41
Loyal Customers	2677	19.37	6149903.0	8.16	23.68	2.99	684.99
Lost	3364	24.34	2391223.0	3.17	68.13	1.00	645.54
At Risk	1729	12.51	1945665.0	2.58	64.38	1.62	620.02
Hibernating	2088	15.11	1480488.0	1.96	21.94	1.00	662.48
Need Attention	719	5.20	589873.0	0.78	25.73	1.44	566.45
Promising	4	0.03	7484.0	0.01	14.50	1.00	605.19

Моделирование спроса

Модель: **RandomForestRegressor**
MAE: 5.73 шт, **RMSE:** 12.87 шт, **R²:** 0.1608;
Главный драйвер — stock_log (55.9% важности).

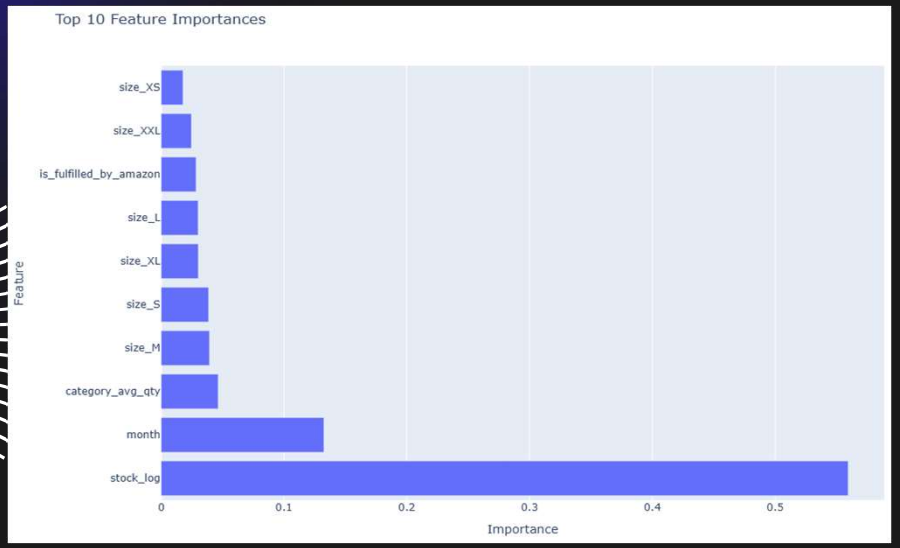

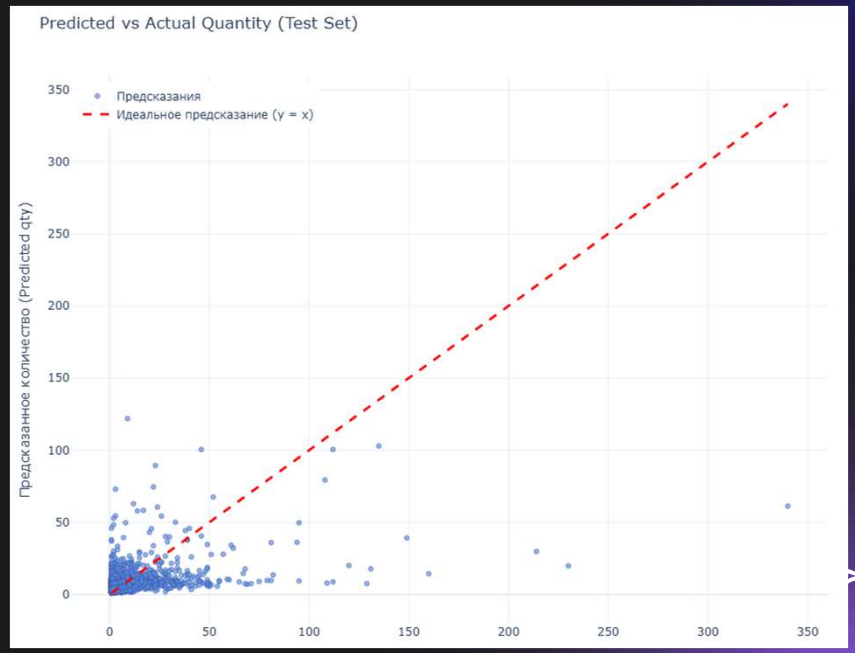

Ограничения проекта

- Короткий период данных (4 месяца) не позволяет полноценно учесть сезонность и долгосрочные тренды.
- Отсутствие реального идентификатора клиента не дало возможности добавить RFM-признаки и клиентское поведение.
- Сильный правый хвост распределения qty усложняет задачу точного прогнозирования.

Бизнес-рекомендации

1. <u>Фокус на ключевых категориях</u>
Увеличить закупки и маркетинговый бюджет на Set и kurta (77% выручки), особенно размеры L, XL, XXL;

2. <u>Управление стоком — критический фактор</u>
Обеспечить наличие популярных SKU (особенно в топ-категориях);
Внедрить автоматические алерты на низкий stock;

3. <u>Максимизировать Amazon Fulfillment</u>
Стимулировать продавцов переходить на Amazon (средний чек в 3+ раза выше);

4. <u>Программа лояльности для топ-клиентов</u>
Разработать персональные предложения и бонусы для сегментов Champions и Loyal Customers (42,8% клиентов → 91,5% выручки);

5. <u>Реактивация спящих клиентов</u>
Запустить недорогие кампании для сегментов At Risk и Hibernating (скидки, напоминания, персональные промокоды).

Итоги и следующие шаги

Итоги проекта

✓ Проведён полный цикл анализа: от очистки данных до моделирования;

✓ Выявлена высокая концентрация выручки (77% от двух категорий, 91,5% от 42,8% клиентов);

✓ Подтверждено ключевое влияние стока и Amazon Fulfillment;

✓ Построен baseline-модель предсказания спроса ($R^2 = 0.16$);

✓ Сформулированы конкретные бизнес-рекомендации.

Следующие шаги

→ Расширить горизонт данных (12+ месяцев);

→ Получить реальный CustomerID. Сделать полноценный RFM и когортный анализ;

→ Добавить признаки: цена, промо, трафик, скидки;

→ Перейти к продвинутым моделям: XGBoost/LightGBM + Tweedie/Quantile;

→ Внедрить мониторинг стока и прогнозирование спроса в реальном времени.

Спасибо за внимание!

Контакты

GitHub: Tema Kiselev (temakiselevv) | **Telegram**: @tema_kiselev

Ссылка на репозиторий: https://github.com/temakiselevv/ecommerce-analytics